

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине «Основы машинного обучения»
**Тема: «Знакомство с анализом данных:
предварительная обработка и визуализация»**

Выполнил:
Студент 3 курса
Группы АС-65
Касьянук К. А.
Проверил:
Крошенко А. А.

Брест 2025

Цель: получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 7

Выборка Auto MPG. Содержит технические характеристики различных автомобилей и данные о расходе топлива (миль на галлон).

Задачи:

1. Загрузите данные. Обратите внимание, что пропуски в столбце horsepower могут быть обозначены знаком (?).

```
import pandas as pd
import matplotlib.pyplot as plt
```

```
data = pd.read_csv(
    "auto-mpg.csv",
    na_values="?"
)

print("Размер датасета:", data.shape)
print(data.head(), "\n")
```

```
Размер датасета: (398, 9)
   mpg cylinders displacement horsepower weight acceleration model year origin          car name
0  18.0           8         307.0      130.0   3504        12.0     70     1 chevrolet chevelle malibu
1  15.0           8         350.0      165.0   3693        11.5     70     1        buick skylark 320
2  18.0           8         318.0      150.0   3436        11.0     70     1  plymouth satellite
3  16.0           8         304.0      150.0   3433        12.0     70     1        amc rebel sst
4  17.0           8         302.0      140.0   3449        10.5     70     1        ford torino
```

2. Преобразуйте столбец horsepower в числовой формат и заполните пропуски средним значением.

```
data["horsepower"] = data["horsepower"].astype(float)

hp_avg = data["horsepower"].mean()
data["horsepower"].fillna(hp_avg, inplace=True)

print(f"Заполненные пропуски horsepower средним: {hp_avg:.2f}\n")
```

Заполненные пропуски horsepower средним: 104.47


3. Постройте диаграмму рассеяния, чтобы изучить зависимость расхода топлива (mpg) от веса автомобиля (weight).

```
plt.figure(figsize=(8, 5))
plt.scatter(
    data["weight"],
    data["mpg"],
    alpha=0.7
)
```

```

plt.title("mpg в зависимости от веса автомобиля")
plt.xlabel("Weight")
plt.ylabel("MPG")
plt.grid(True)
plt.show()

```



4. Преобразуйте категориальный признак origin (страна производства) в числовой.

```

origin_labels = {
    1: 0,
    2: 1,
    3: 2
}

data["origin"] = data["origin"].replace(origin_labels)
print("Уникальные значения origin:", data["origin"].unique(), "\n")

```

Уникальные значения origin: [0 2 1]

5. Создайте новый признак age, рассчитав возраст автомобиля относительно года, когда были собраны данные (например, 1983 - model year).

```

collection_year = 1983
data["age"] = collection_year - (data["model year"] + 1900)

print(data[["model year", "age"]].head(), "\n")

```

	model	year	age
0		70	13
1		70	13
2		70	13
3		70	13
4		70	13

6. Визуализируйте распределение количества цилиндров (cylinders) с помощью столбчатой диаграммы.

```
cyl_counts = data["cylinders"].value_counts().sort_index()

plt.figure(figsize=(6, 4))
plt.bar(
    cyl_counts.index.astype(str),
    cyl_counts.values
)
plt.title("Распределение автомобилей по количеству цилиндров")
plt.xlabel("Cylinders")
plt.ylabel("Количество")
plt.show()
```



Вывод: получили практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научились выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.